

DATA MINING PROJECT

도쿄 에어비앤비 데이터 기반 신규 호스트 투자 최적스팟 및 마진 극대화 전략

데이터 마이닝 4조 - 곽정원 강시현 강준우 장민석

<https://github.com/KsiH71/tokyo-airbnb-analysis>

배경 및 분석 목적

왜 도쿄 에어비앤비인가?

- 일본 인바운드 관광객 2023년 2,507만 명 — 코로나 이후 급반등, 도쿄 숙박 수요 폭증
- 에어비앤비 신규 호스트 진입 증가 — 그러나 가격 책정 기준 없이 감에 의존하는 현실
- 정보 비대칭 문제 — 어느 위치에서, 어떤 옵션을 갖춰야 수익이 나는지 데이터 기반 근거 부재

분석 목적

" 도쿄 에어비앤비 가격 결정 요인을 분석하여, 제한된 자본을 가진 신규 호스트가 수익을 극대화 할 수 있는 최적의 입지/시설/운영 전략을 정량적으로 제시"



데이터 소개


① Inside Airbnb

- 출처: insideairbnb.com
- 수집 시점: 2024년 기준
- 원본 행 수: 약 17,000개
- 분석 사용: 12,222개 (2~4인용)
- 주요 변수: 가격, 수용인원, 편의시설, 평점, 호스트 정보, 위치 좌표



② 국토교통성 GIS

- 출처: 일본 국토교통성 국토수치정보
- 데이터: 전국 철도역 좌표 (위경도)
- 도쿄 권역 역 수: 662개
- 활용: 최근접 역까지 거리(m) 계산
- 방식: 위경도 기반 유클리드 근사



③ 도쿄 공시지가

- 출처: 일본 국토 지가공시
- 단위: 엔/㎡
- 커버리지: 도쿄 47개 구·시
- 활용: 숙소 위치 기준 nearest 매칭
- 목적: 투자 비용 대비 수익 효율 산출



데이터 통합 및 분석 프로세스

01. 데이터 전처리

GIS 좌표 변환 및 이중 데이터
결합, 이상치 제거

02. 모델링

RF, GBM, Ridge 비교
RandomForest 채택

03. 심층 분석

변수 중요도 및
역 거리 시뮬레이션

04. 전략 도출

호스트 가이드라인 및 투자 스
위트스팟 제안

Detailed Integration Flow

Inside Airbnb

숙소 위도·경도
12,222행 × 70개

→
각 숙소와
역 위경도 계산

국토교통성 GIS

역 위도·경도 662개
dist_to_station

→
숙소와 공시지가
최근접 매칭

도쿄 공시지가

구·시별 지가 포인트
land_price 매칭

→
최종 병합

최종 분석 데이터

가격 + 위치 + 지가
통합

- GIS 결합: 각 숙소 좌표 기준 662개 역 중 최근접 역까지의 직선거리(m)를 계산하여 dist_to_station 변수 생성
- 지가 결합: 숙소 위치 기준 가장 가까운 공시지가 측정 포인트의 값을 land_price로 매칭 (Nearest Neighbor 방식)

전처리

로그 변환

변수: price

변환 사유: 데이터 정규성 확보 및 이상치 왜곡 완화

변환 전 ~ 변환 후 : 15000엔 ~ 9.61

로그 변환

변수: land_price

변환 사유: 경제학적 탄력성 해석력 확보

변환 전 ~ 변환 후 : 1200000엔 ~ 13.99

이상치 제거

변수: price

변환 사유: 극단적 이상치 제거를 통한 모델 일반화

변환 전 ~ 변환 후 : 12222건 ~ 11977건

이진화 변환

변수: host_is_superhost

변환 사유: 범주형 변수 및 비정형 텍스트 수치화

변환 전 ~ 변환 후 : 0 또는 1

단위 정형화

변수: price, response_rate

변환 사유: 특수문자 파싱 후 연속형 실수 변환

변환 전 ~ 변환 후 : \$12600 ~ 12600, 80% ~ 0.8

단위 정형화

변수: dist_to_station

변환 사유: 지리적 거리 데이터의 공간적 스케일 통일(m->km)

변환 전 ~ 변환 후 : 980.55m ~ 0.98km

분석 Formulation

Instance (분석 단위)

도쿄 에어비앤비 숙소 1개 = instance / 총 11977개 사용
범위 : 2~4인용 숙소로 한정

Output (예측 대상)

1박 가격(엔) - 연속형 수치 - 회귀(Regression)문제
로그 변환 후 예측 - 역변환 도출 ($\log_{1p}/\exp_{m1}$)


Task 유형

Supervised Learning - Regression
모델: RandomForest / GradientBoosting / Ridge

Input

변수 그룹	주요 변수
위치 (Location)	dist_to_station, dist_to_Tokyo, land_price 등
내부 스펙 (Spec)	accommodates, bedrooms, room_type, 편의시설 7종
리뷰 (Review)	review_scores_rating, cleanliness 등 7종
호스트 (Host)	host_is_superhost, response_rate, acceptance_rate

모델 성능 및 검증 (RandomForest)



예측력 확보 ($R^2=0.68$)

단순 선형 회귀보다 비선형 관계를 잘 포착하는 RandomForest 모델이 가장 우수한 성적을 기록했습니다.

주요 지표:

Ridge (L2)	0.47	선형관계만 포착
Gradient Boosting	0.60	순차학습, 느림
Random Forest	0.68	최종채택

- 분류 모델 검증 결과, 저가 및 중가 숙소의 예측 정확도가 특히 높게 나타남.
- "5-Fold 교차검증으로 과적합 여부 확인 — Train/Test 성능 차이 안정적"


가격을 결정하는 핵심 요인 Top 20

개별 변수 영향력 분석

- ✓ 1위: 도쿄역까지의 거리 — 비즈니스·환승 거점, 연중 안정적 수요
- ✓ 2위: 시부야역까지의 거리 — 관광 수요 집중, 접근성이 가격 프리미엄
- ✓ 3위: 수용 인원 — 인원 증가 시 가격 상승, 그룹 수요 프리미엄
- ✓ 4위: 공시지가 — 땅값이 비쌀수록 숙박가격도 높다


Top 20 변수 중 %가 역 거리 변수 — 입지가 가격의 핵심 결정자

가격 영향 변수 Top 20
(Model: RandomForest)



위치 vs 내부 조건: 무엇이 더 중요한가?

변수군별 가격 영향 비중
위치 vs 내부스펙 vs 리뷰 vs 호스트 vs 예약



압도적인 입지의 가치 (49.6%)

변수를 성격별로 5개 그룹으로 묶어 분석한 결과, 입지 조건이 가격의 절반 이상을 설명합니다.

49.6%

위치 (Location)

21.0%

내부 스펙 (Spec)

13.1%

리뷰 평점 (Review)

9.2%

호스트 속성 (Host)

도쿄 중심부에 집중된 초고가 숙소

지역별 평균 숙소 가격 지도

- ✓ 최고가 지역은 최저가 대비 약 2.7배
- ✓ 고가 지역은 도심 동남부에 집중
- ✓ 외곽(서쪽)으로 갈수록 가격 급락

도심지 접근성과 가격 사이에서 타협점을 찾는 것이 중요

초고가 지역 (상위 15% 기만)

- Chuo Ku: 22,128엔/㎡
- Minato Ku: 21,225엔/㎡
- Shibuya Ku: 19,447엔/㎡
- Chiyoda Ku: 18,128엔/㎡
- Taito Ku: 16,972엔/㎡

고가 지역


- Shinjuku Ku: 16,452엔/㎡
- Bunkyo Ku: 15,331엔/㎡
- Meguro Ku: 14,795엔/㎡
- Musashino Shi: 14,253엔/㎡
- Koto Ku: 14,094엔/㎡
- Sumida Ku: 14,083엔/㎡

하위권 지역 (하위 25%)

- Katsushika Ku: 10,030엔/㎡
- Ota Ku: 9,935엔/㎡
- Nerima Ku: 9,858엔/㎡
- Kiyose Shi: 9,695엔/㎡
- Mitaka Shi: 9,635엔/㎡
- Adachi Ku: 9,044엔/㎡


[주요 인사이트]

- 중앙값: 12,636 엔/㎡
- 최저가: Machida Shi 8,187엔/㎡
- 최고가 지역은 최저가 대비 2.7배 단가
- 고가 지역 도심 동남부 집중 경향



공시지가 대비 숙박가격

신규 호스트 스위트스팟 전략
[공시지가 vs 숙박가격] 지역별 비교



효율적인 지역 선택 전략

시부야, 미나토 같은 초고가 지역보다 전략적 고가 지역의 투자 효율이 높음.


구분	공시지가	숙박가격	효율
초고가	231만엔	19,832엔	85.8
고가	126만엔	15,157엔	120.3
중위권	136만엔	14,357엔	105.5

하위권 — 도쿄 관광객 대부분이 야마노테선 내권 안에서 이동하는 특성상 외곽은 에어비앤비 수요 모수 자체가 다름

2. 초고가 제외고가 지역 대비 공시지가는 45% 저렴하지만 숙박가격은 24% 밖에 차이 안남

역 거리별 투자 효율 스위트스팟 예측

[PD] 역 거리별 투자 효율 스위트스팟
(X 전체 평균 예측가 vs 공시지가, n=11,977)




어디가 최고의 장소일까

내부 스펙을 동일하게 고정하고 역까지의 거리만 변화시킨 결과, 1 ~ 1.2 km 사이의 지역이 최고의 스위트 스팟으로 예측되었습니다.

- 0.0 ~ 0.8km: 역에서 가까워 숙박비를 비싸게 받을 수 있음.
하지만 공시지가가 단가도 높아 초기 투자금 너무 높음.
따라서 실질적인 수익률은 떨어짐.
- 1.0 ~ 1.25km: 최적 구간 (효율 최고)
- 1.25km 이상: 하락세 (소비자에게 외곽으로 인식)

머신러닝 기반 핵심 변수별 순수 가격 기여도


교란변수를 통제한 순수 효과



- ✓ 수용인원 3→4인 확장: +2,612엔 — 압도적 1위 전략
- ✓ 엘리베이터: +864엔
- ✓ 수용인원 2→3인 확장: +774엔
- ✓ 1침실→2침실: +668엔
- ✓ 숙소유형 private→entire: +382엔
- ✓ 역 1km vs 0.5km: +352엔

내부스펙에 따른 가격 차이 분석

방 유형 · 수용인원 — 모델 기반 예측 단가



방 유형별 예측 단가

- Entire home/apt: 15,006엔
- Private room: 14,624엔


→ 교란변수 통제 시 방 유형 차이는 +382엔으로 크지 않음

수용인원별 예측 단가(독채 기준)

- 2인 → 3인: +778엔
- 3인 → 4인: +2578엔 → 단가 급상승

가성비 어메니티 투자 전략

고효율 vs 역효과 옵션




설치 권장 (순수 효과 +)

- 엘리베이터: +864엔 — 어메니티 중 1위
- 주방(Kitchen): +259엔
- 세탁기: +258엔

효과 미미 / 역효과

- wifi +15엔
- self check-in: -5엔, 에어컨: -29엔 (역효과)

무형 자산의 가치: 슈퍼호스트



슈퍼호스트

슈퍼포스트 순수 프리미엄

+1029엔 (6.9%)

일반 호스트 대비 가격 프리미엄



빠른 응답률(90%) 및 예약 취소 최소화(1% 미만)



고객 평점 관리 (4.8점 이상)



연간 10회 또는 100박 이상 예약

종합 가이드라인 및 기대 효과

최적 입지

시나가와, 타이토, 스미다 등 고가~중위 지역
역으로부터 1.0km~1.25km 구간 매입

필수 스펙

수용인원 3~4인 최적화, 침실 수 확대
세탁기, 주방 등 고효율 어메니티 선별

운영 전략


슈퍼호스트 배지를 취득
- 프리미엄 가격

① 신규 호스트 의사결정 지원

감에 의존하던 가격 책정을 데이터 기반으로 전환, 초기 투자 리스크 감소

② 시설 투자 우선순위 제공

세탁기·주방 등 고효율 어메니티 선별, 엘리베이터·와이파이 등 순수 효과 미미 옵션
식별



시부야의 아파트

★ 신규

#304/44㎡/시부야역 도보 8분/관광 및 쇼핑...
침대 4개 · 욕실 1개

총액 ₩324.047

3. 숙소 소개글 및 썸네일

변수 중요도에 따른
강조할 특성 언급

"위치·시설·지가를 결합해 신규 호스트의 자본 효율 전략을 정량적으로 도출 — 데이터 마이닝의 실용적 적용 사례"

연구의 한계점 및 향후 과제

결과를 어디까지 일반화할 수 있는가

범위 한정

"2~4인용 숙소로 분석 범위를 제한 — 1인 · 단체 · 대형 숙소에는 직접 적용 어려움"

초기자금 계산 부재

“실제 운영 수익성 산정에 필요한 초기 설비·인테리어 비용, 관리비, 플랫폼 수수료 등 부대비용 데이터가 부재하여 순수익 기반 분석에는 한계가 있음”

정량적 스펙에만 국한

숙소의 뷰와 내부 인테리어 등 심미적 요소를 고려하지 않음
+추후 이미지 인식을 활용해 숙소 사진의 인테리어 점수를 변수로 추가

향후 과제

마진 극대화라는 주제가 아닌, 투자 효율 및 가격 경쟁력/
예약률 상승방안을 모색하는 것이 적합해보임

그럼에도 — *위치 · 시설 · 지가*를 결합해 신규 호스트의 *자본 효율 전략*을 정량적으로 도출한 데 의의

Thank You!



질문 및 답변

도쿄 에어비앤비 가격 결정 요인 분석 프로젝트

데이터 마이닝 4조